資訊管理學系 陳士杰老師

作業系統
Operating Systems

磁碟管理
Disk Management

國立聯合大學
NATIONAL UNITED UNIVERSITY

■本章重點

- Free Space Management (可用空間管理)
- Allocation Methods (檔案配置方式)
- Disk Access Time
- Disk Scheduling Algorithms
- RAID
- Solid State Disk

Free Space Management

- 基本概念：Disk Allocation/Free Space單位是以 “區塊” (Block) 為主。

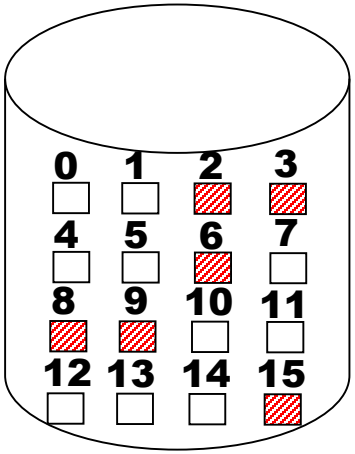

- 方法：
  - Bit Vector (Bit Map)
  - Link List
  - Combination
  - Counting

Bit Vector

- Def: 用一組Bits來代表Blocks配置與否，一個Bit對應一個Block。
  - Bit值 = 0，表示Free
  - Bit值 = 1，表示Allocate

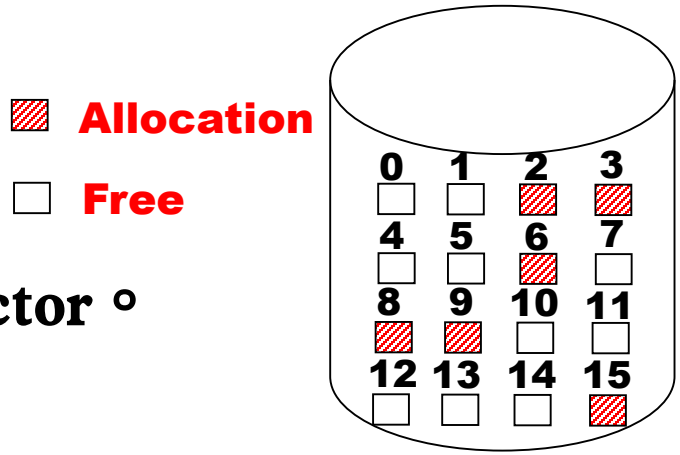

- 範例：如右圖，請列出其Bit Vector。
  - 0011001011000001
- 優點：
  - Simple
  - 易於找到連續可用空間 (即：找到連續的 “0”)
- 缺點：
  - Bit Vector儲存佔用Memory空間，所以此法不適用於大型Disk
    (∵若Block有上百萬個，則Bit Vector會非常大，Memory可能會容納不下)

Link List

- Def: 利用Link List將Free Block串接，形成一個AV List。

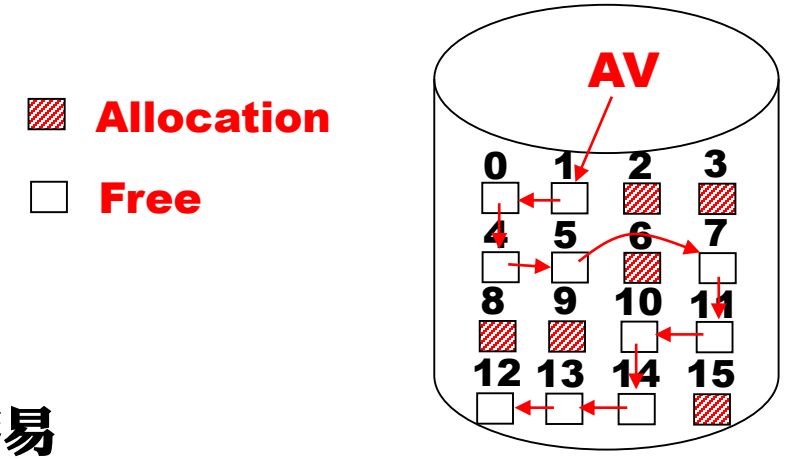

- 優點：
  - 加入/刪除Block容易
- 缺點：
  - 效率不佳。因為在找尋可用區塊時，需從頭檢視此串列，I/O Time過長 (∵檢視一個Block就須做一次I/O)

Combination (組合法)

- 取某個可用區塊，記錄其它可用區塊之編號。若此區塊不足以容納所有的Free Block 編號，則再以其它區塊記錄，並用 Link 串連。

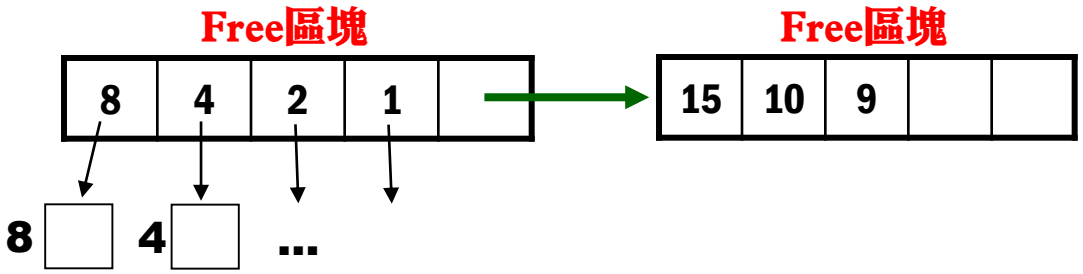

- 優點：
  - 加入/刪除Block容易
  - 可迅速取得大量可用區塊
- 缺點：
  - 效率不佳，I/O Time過長

Counting

- 適用於連續區塊較多之情況。在一個Free Block中，記錄其後的連續可用區塊數目 (含自已)。

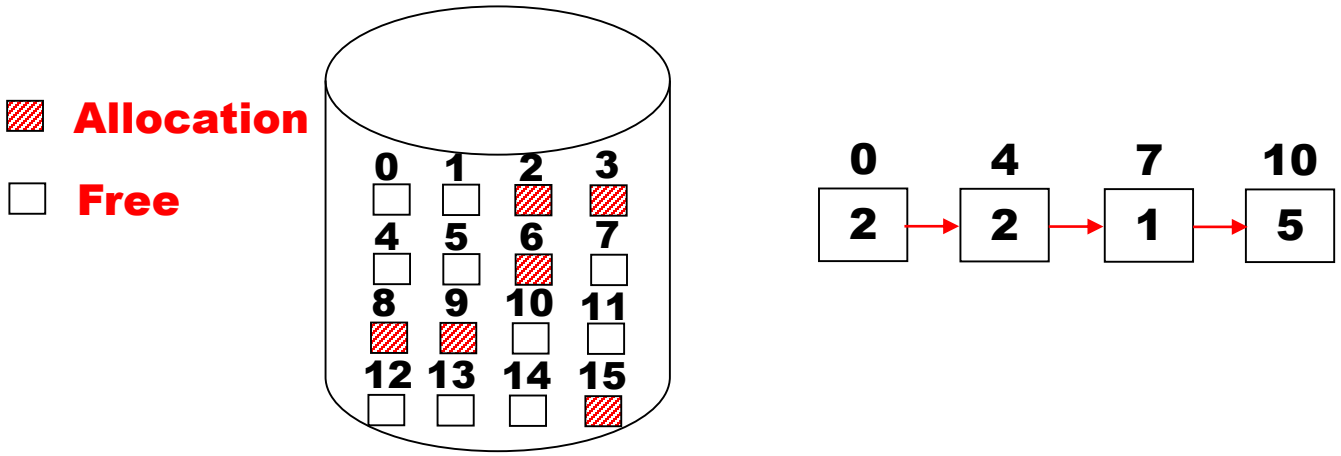

- 如果連續區塊數目夠多，則Link List長度可大幅縮短。

Disk結構

- Track (磁軌)
- Sector (磁區)
- Cylinder (磁柱)
  - 不同面之相同Tracks形成之集合
- Read/Write Head (讀寫頭)

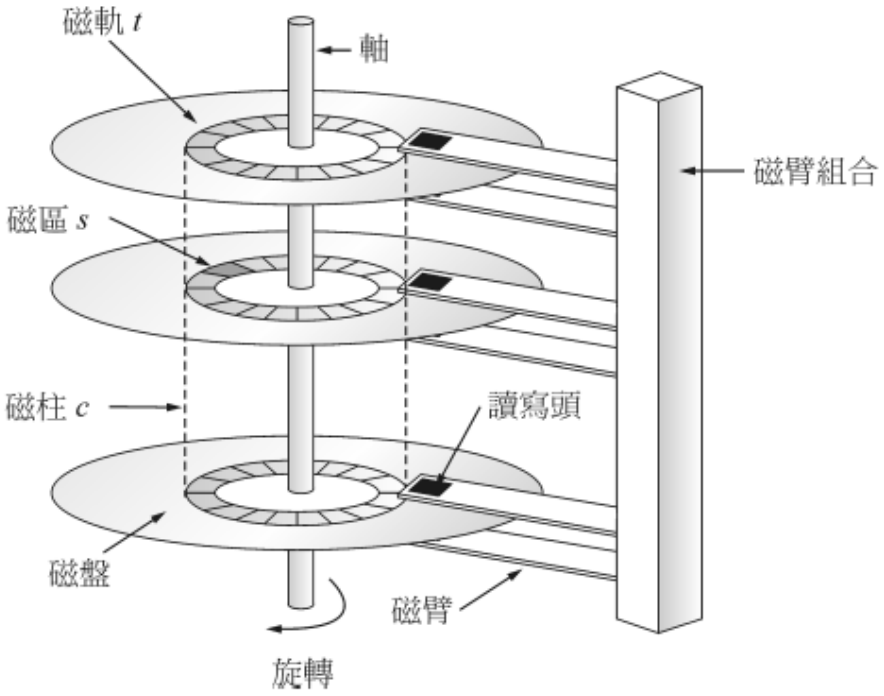

圖 12.1 移動磁頭的磁碟機制

Disk Capacity

- 若某硬碟有10個Disks，正反面皆可存Data，但最上、最下一面不存。每一個表面上有1024條Tracks，每個Track有256個Sectors。一個Sector可存512 Byte資料，則磁碟的容量為何？

Ans:

$$(10 \times 2 - 2) \times 1024 \times 256 \times 512 \text{ Bytes} = 18 \times 2^{10} \times 2^{8} \times 2^{9} \text{ Bytes}$$

$$= 18 \times 2^{7} \text{ MB}$$

Disk Access Time

- 由下列3個時間加總：
  - Seek Time
    - 將Read/Write Head移到指定Track上方所花的時間
  - Latency (Rotation) Time
    - 將欲Access的Sector轉到Read/Write Head下方所花的時間
  - Transfer Time
    - 資料在Disk及Memory之間的傳輸時間
- 上述三者以Seek Time耗時最多
  - ∵是機械動作
  - 與 “Disk Scheduling Algorithm” (磁碟排班演算法)及 “Track service request arrival order” (Track 服務請求之到達順序)

Disk Scheduling Algorithms

- FCFS
- SSTF
- SCAN
- C-SCAN
- LOOK
- C-LOOK
- 說明範例：
  - 目前的磁頭位於53軌。磁碟緩衝區內的磁軌讀、寫要求依序為：

    98，183，37，122，14，124，65，67

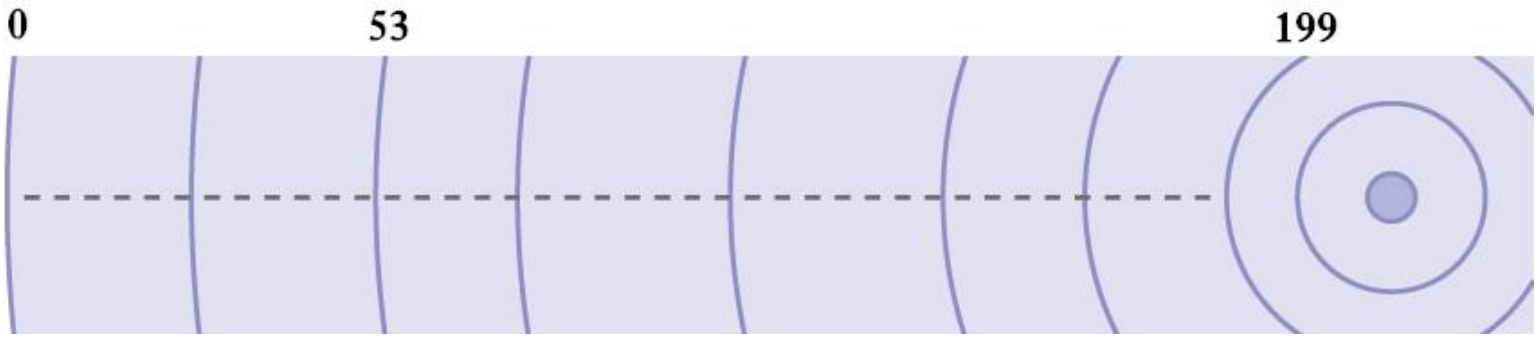

FCFS演算法 (first-come, first-serve)

- 先到達的Track Request優先服務
  - 範例：有下列的Track請求於佇列當中，採用FCFS，則Track移動總數為何？

佇列=98,183,37,122,14,124,65,67

讀寫頭自 53 啟始

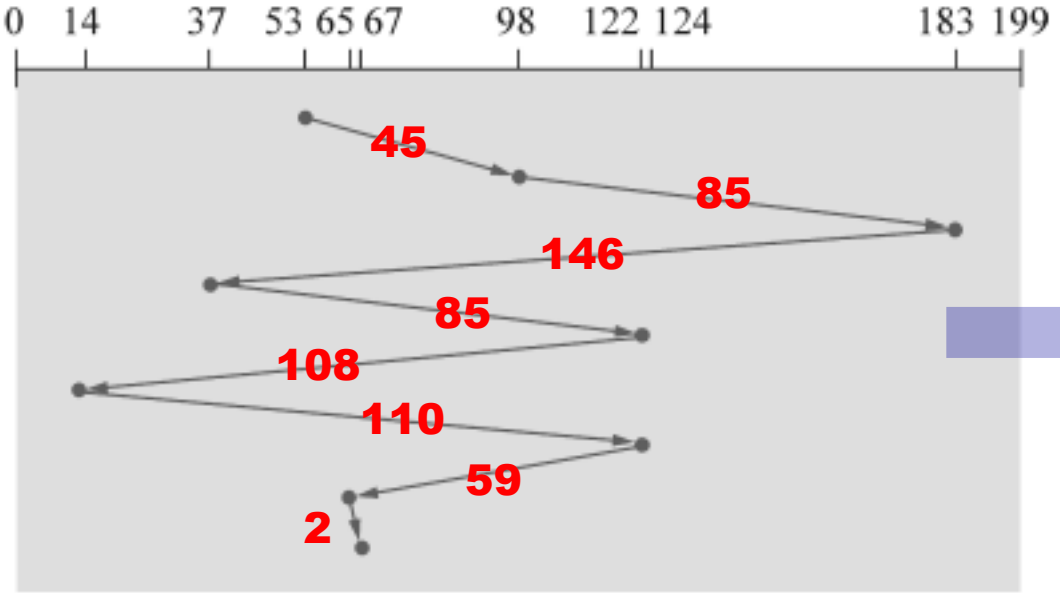

45
85
146
85
108
110
59
\+ 2

640

圖 12.4 先來先服務的磁碟排序

- **特點：**
  - Simple
  - 公平的 (不會發生Starvation)
  - 效果不佳 (Avg. Seek Time ↑)

SSTF演算法 (short-seek time first)

- 距離目前R/W Head最近的Track優先服務
  - 範例：有下列的Track請求於佇列當中，採用SSTF，則Track移動總數為何？

佇列=98,183,37,122,14,124,65,67
讀寫頭自 53 啓始

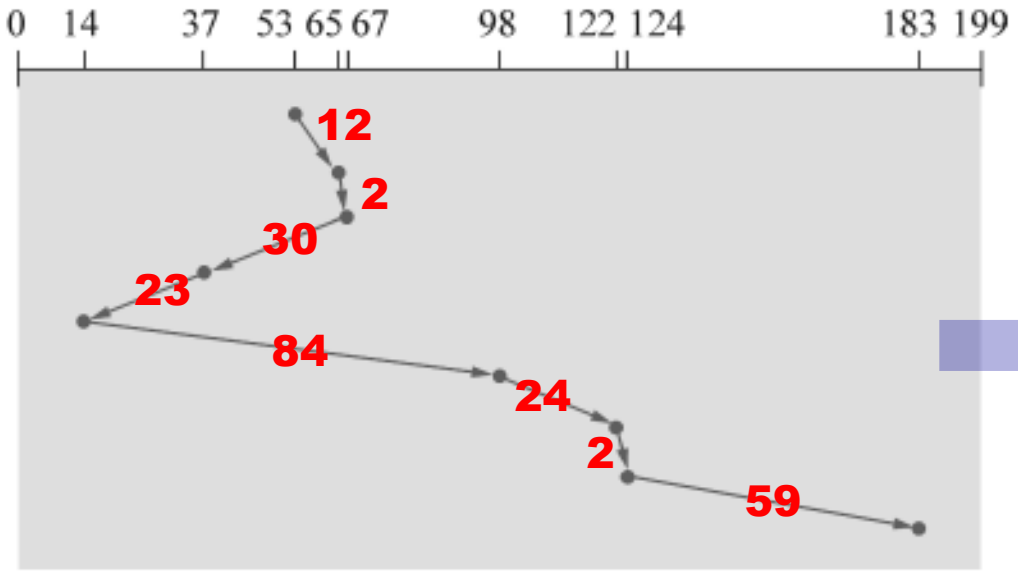

12
2
30
23
84
24
2
\+ 59
236

圖 12.5 最短尋找時間的優先服務之磁碟排序

- **特點：**
  - **並非是最佳的 (∵平均移動的Track總數量無法保証為最少)**
  - **不公平，可能會發生Starvation (若後續進來的Track請求皆是在讀寫頭附近的話，則距離讀寫頭最遠的Track請求可能會餓死)**

SCAN演算法

- 讀寫頭來回不停地掃描，若有Track請求，則服務。
  - 提供**雙向服務**
  - 遇到Track起頭與尾端才折返。
- 範例：

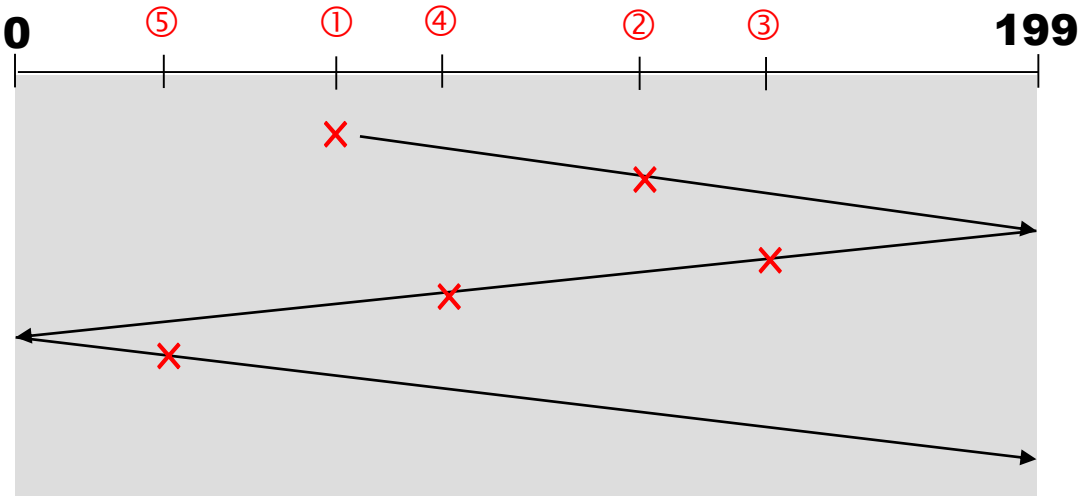

- 特點：
  - 因為要碰到起頭或尾端才會折返，會有一些不必要的磁軌移動產生
  - 相對不公平，但不會發生Starvation

佇列=98,183,37,122,14,124,65,67

讀寫頭自 53 啓始

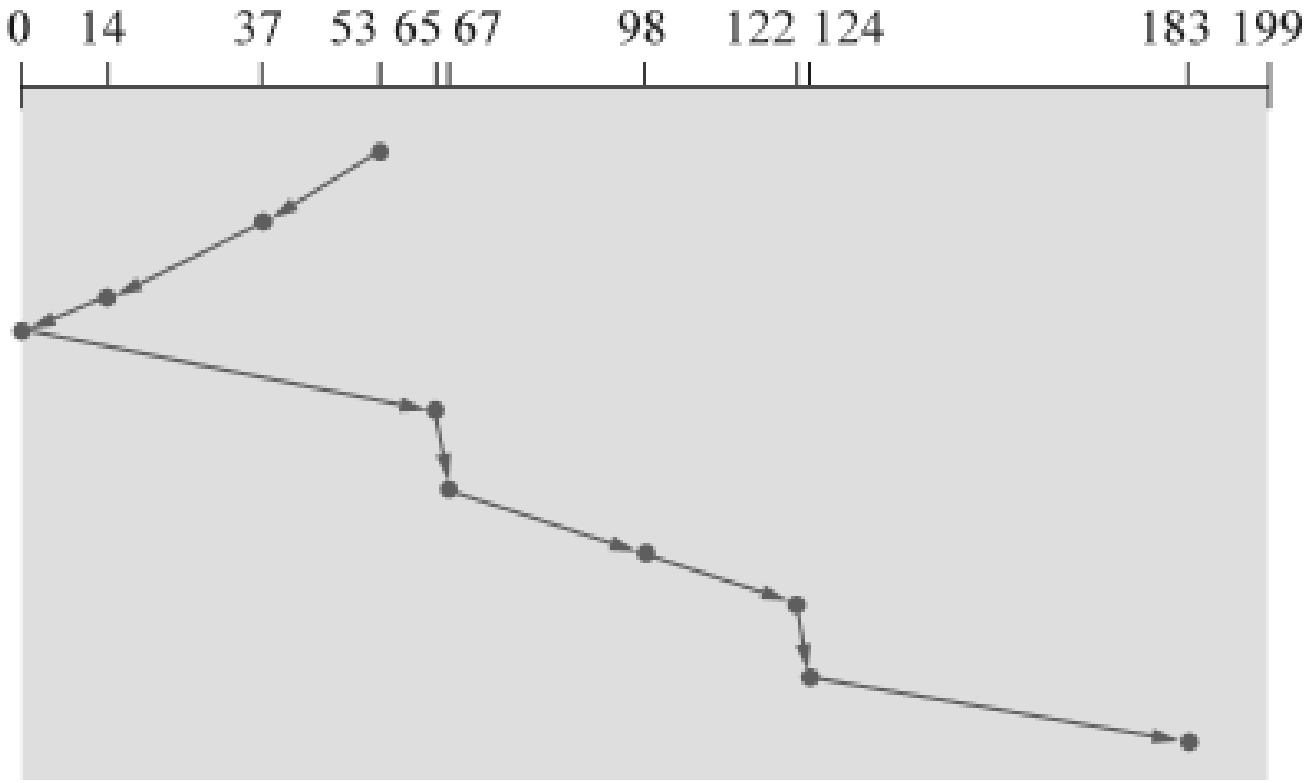

圖 12.6 SCAN 磁碟排序

C-SCAN演算法

- 讀寫頭來回不停地掃描，若有Track請求，則服務。
  - 提供**單向服務**
  - 遇到Track起頭與尾端才折返。
- 範例：

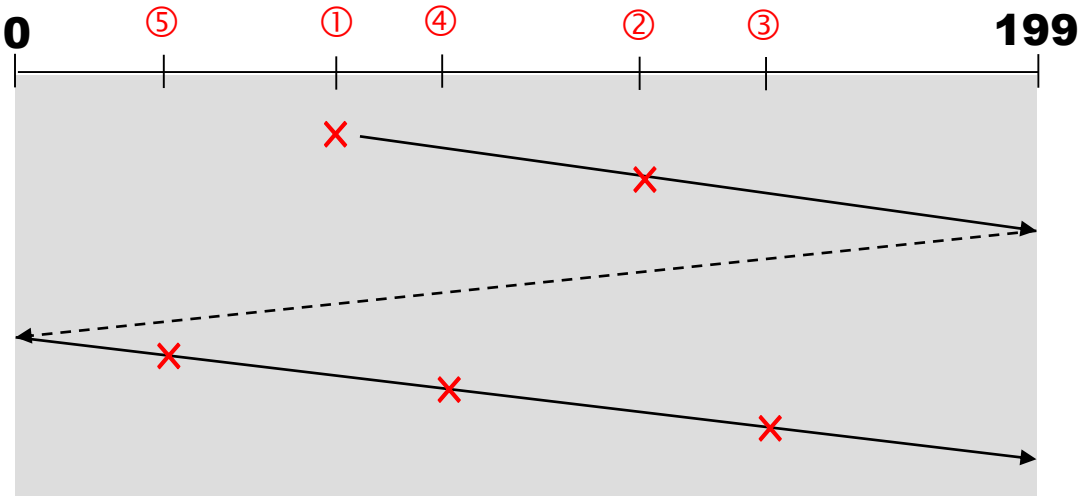

佇列=98,183,37,122,14,124,65,67

讀寫頭自 53 啓始

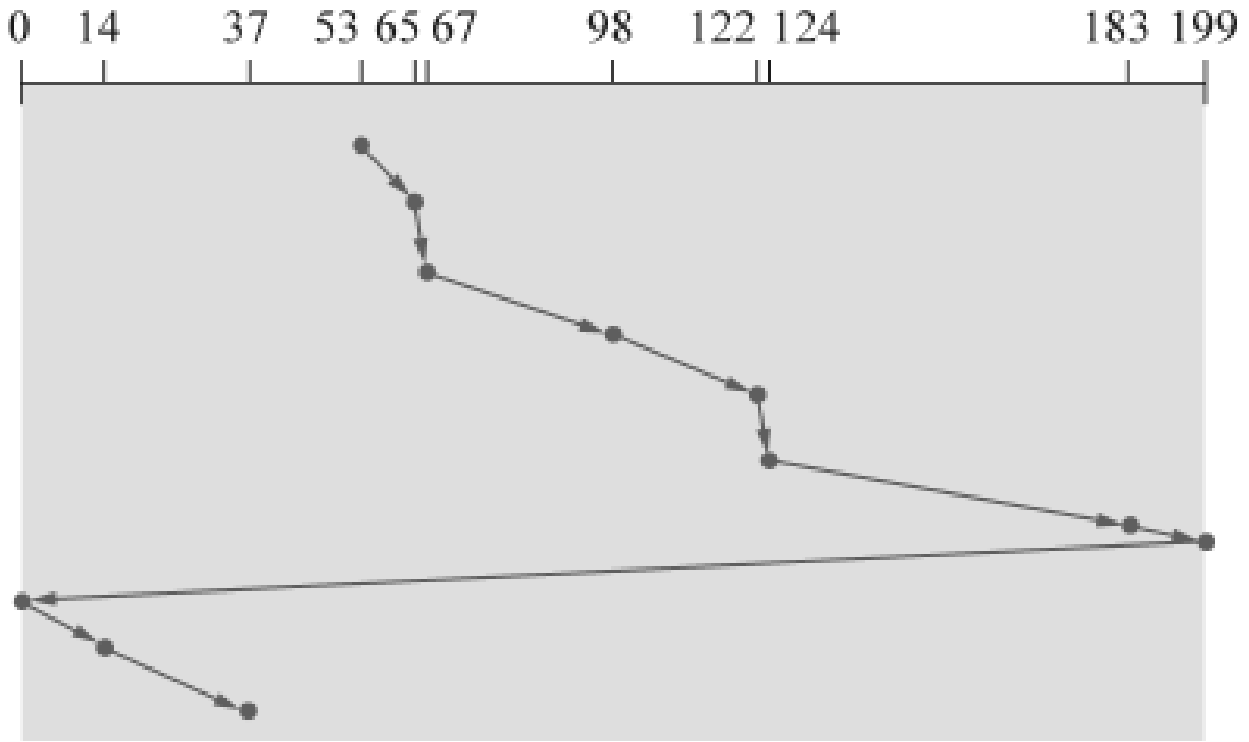

圖 12.7　C-SCAN 磁碟排序

LOOK演算法

- 讀寫頭來回不停地掃描，若有Track請求，則服務。
  - 提供**雙向服務**
  - 處理完某方向的最後一個Track請求，即折返服務，不需遇到Track起頭與尾端才折返。
- 範例：

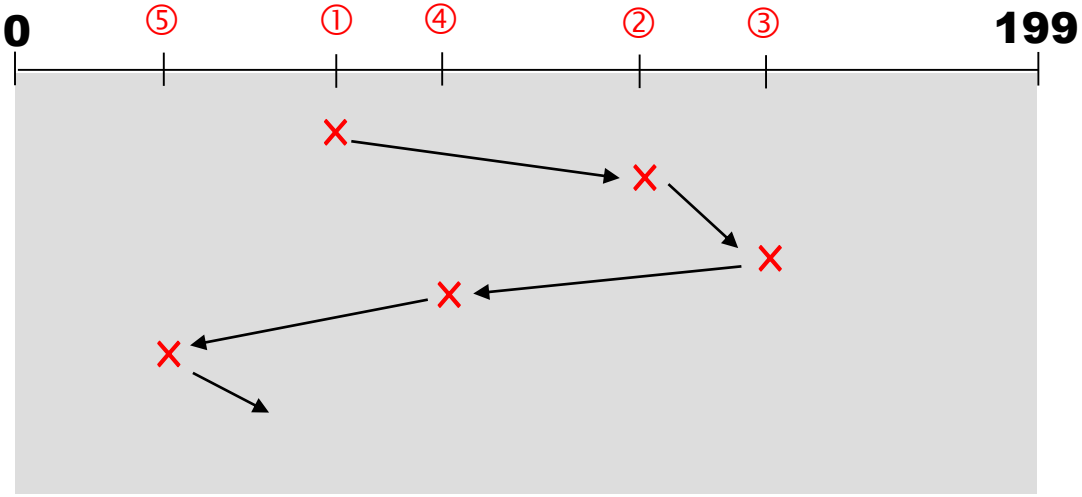

C-LOOK演算法

- 讀寫頭來回不停地掃描，若有Track請求，則服務。
  - 提供**單向服務**
  - 處理完某方向的最後一個Track請求，即折返服務，不需遇到Track起頭與尾端才折返。
- 範例：

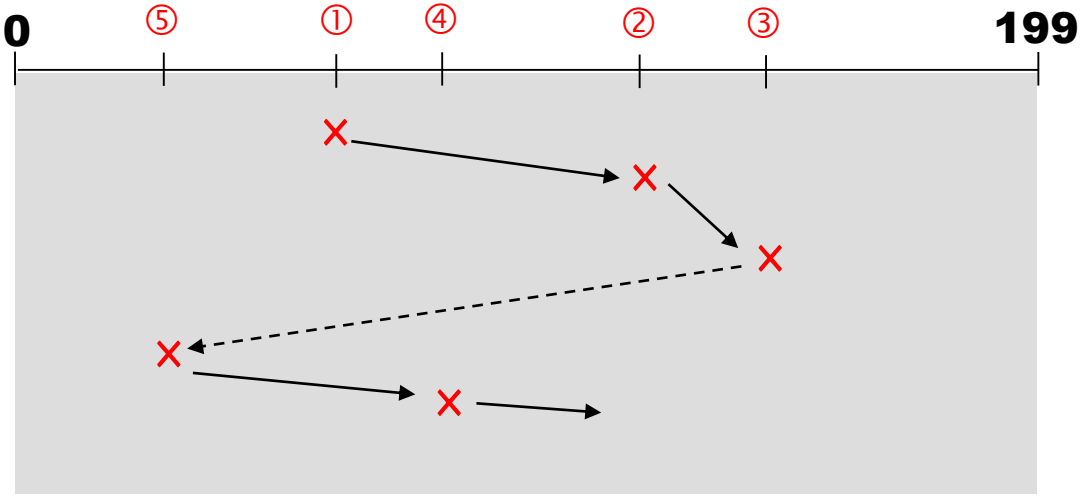

佇列=98,183,37,122,14,124,65,67

讀寫頭自 53 啓始

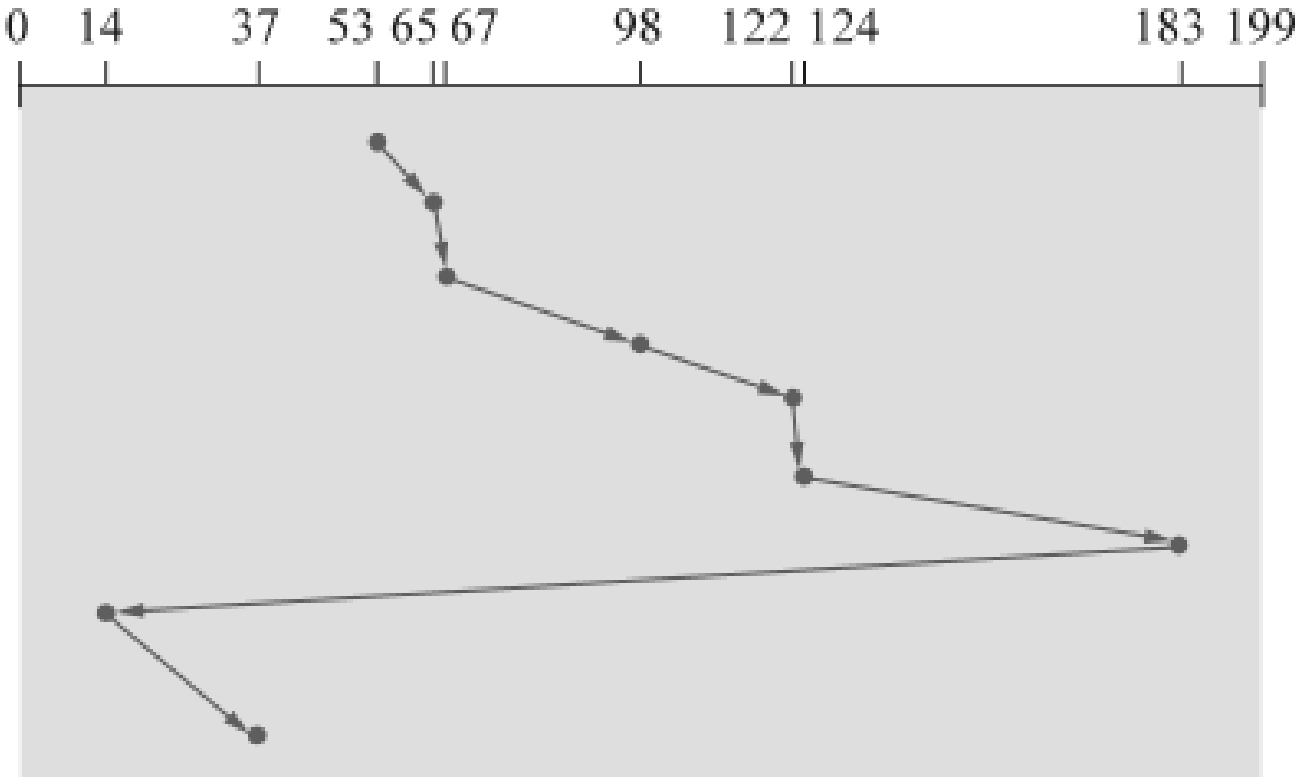

圖 12.8　C-LOOK 磁碟排序

Allocation Methods (檔案配置方式)

- Disk配置給File所需之區塊的方式有四：
  - Contiguous Allocation
  - Linked Allocation
  - FAT
  - Index Allocation

Contiguous Allocation (連續性配置)

- 若File大小為n個Blocks，則OS必須在Disk上找到大於等於n個連續Free Blocks才能配置。
- Physical Directory的記錄方式：

  File Name, Size, Starting Block #

  - Physical Directory是給OS看的
  - Logical Directory是給User看的 (如：dir或是檔案總管中的資訊)
- 範例：若File 1要求4個Blocks大小的空間。

Allocation

Free

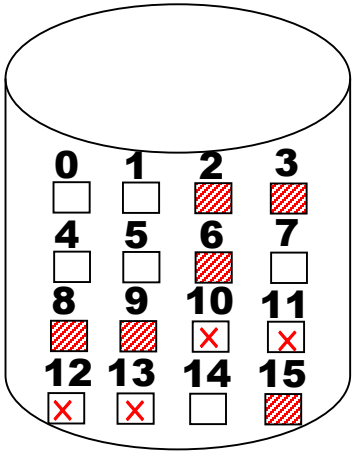

File Name	Size	Starting Block #
File 1	4	10

- **優點：**
  - 可支援Sequential Access及Random Access
  - Seek Time 通常較短 (∵File所佔的連續區塊大都會落在同一個Track或鄰近的Track上)
- **缺點：**
  - 易遭受External Fragmentation Problem
    - 以前例來說，若有一個File要7個Block，Disk中可用的Block有10個，卻因為空間不連續而無法配置給該File使用。
  - 檔案大小無法任意增/刪
    - 有些File是動態的，如：交易檔。但連續配置時，若某一已被配置之動態檔案，其位置前後的空間都已被配置給其它檔案，此時就無法動態增加該檔案的資料了。
  - 建檔時須事先宣告大小

Link Allocation (連結配置)

- 若File 大小為n個區塊，則OS必須在Disk上找到 ≥ n個可用區塊即可配置(不一定要連續)。各配置區塊之間以Link來做串連。
- Physical Directory的記錄方式：

  File Name, Start Block #, End Block #

- 範例：若File 2要求5個Blocks大小的空間。

Allocation

Free

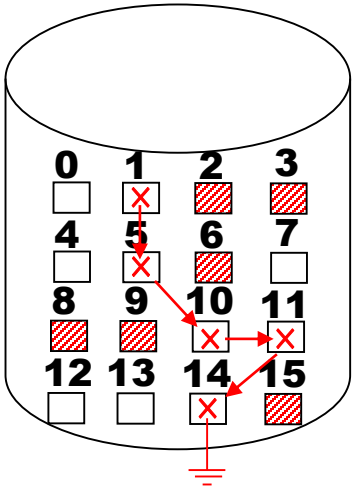

File Name	Star Block #	End Block #
File 2	1	14

⇨Block內會有幾個byte是存放連結的。最後一個block有無存null皆無妨!!∵有End Block #的記錄在。

- 優點：
  - 沒有External Fragmentation Problem
  - File可任意增/刪空間
  - 建檔時，無需事先宣告大小
- 缺點：
  - 不支援Random Access
    - 要讀某個File的某個區塊時，需從頭找起。∴只支援Sequential Access。
  - Seek Time比Contiguous配置方式長
    - ∵非連續性的Blocks可能散落在許多不同的Track上。
  - Reliability差
    - 若Link斷裂，則Data block lost。

FAT (File Allocation Table)

- 為Link Allocation的變形。將所有配置區塊之間的Link及Free Block資訊全部記錄在一個Table中，此Table稱之為FAT。
  - 若Disk有n個Blocks，則FAT有n個項目 (不論是Free的還是使用中的Block皆需記錄)
  - FAT中的項目資訊：
    - 空白：表示Free Block
    - 某Block #：有Link指向此Block，即使用中的Block
    - EOF：End of File
  - MS-DOS及OS/2採用
- Physical Directory的記錄方式：

  File Name, FAT Index

- 範例：若File 3要求5個Blocks大小的空間。

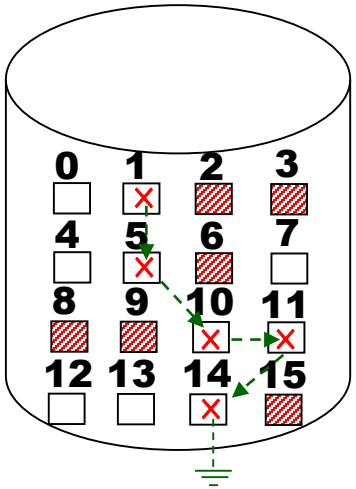

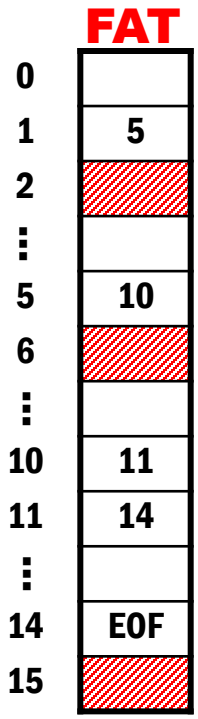

File Name	FAT Index
File 3	1

⇨FAT Index = 1表示由第1個Block開始。

- Block可完全都存放Data，不像Link Allocation會有幾個Byte用來存放連結。
- 優缺點和Link Allocation差不多

Index Allocation (索引式配置)

- 每個File皆會多配置一些額外的Blocks作為Index Blocks，內含各配置的Data Block編號。採非連續性配置方式。
- Physical Directory的記錄方式：

  File Name, Index Block #

- 範例：若File 4要求4個Blocks大小的空間。
  - 會配到5個Blocks (1個Index Block + 4個Free Blocks)
  - 假設1個Index Block可存10個Block #

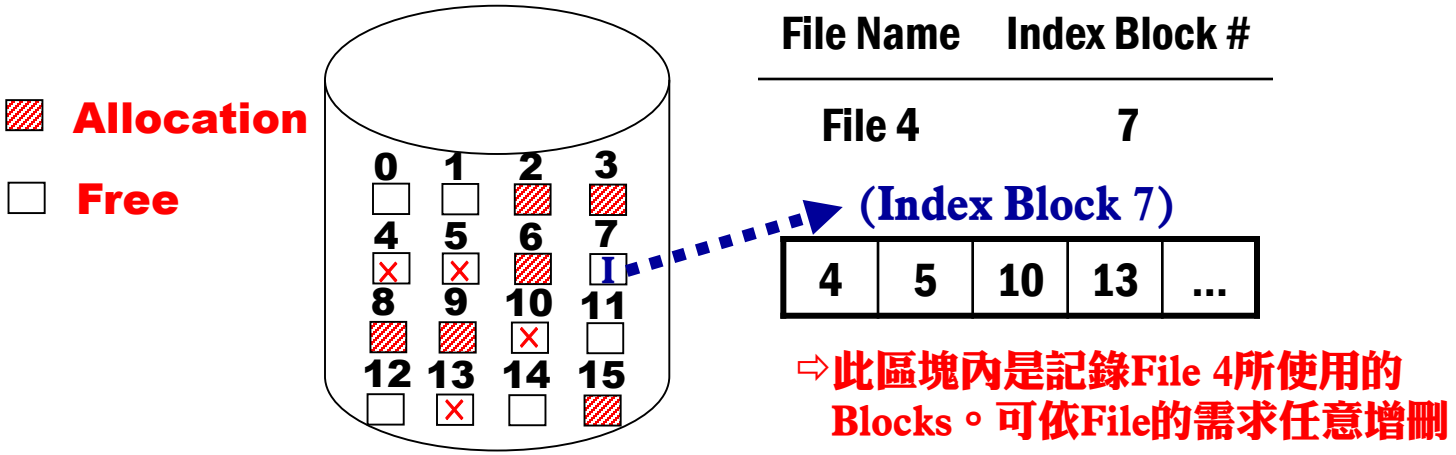

- 優點：
  - 沒有External Fragmentation Problem
  - 支援Random Access及Sequential Access
  - File可任意增/刪空間
  - 建檔時，無需事先宣告大小
- 缺點：
  - Index Blocks佔用額外空間
    - 索引區塊佔用了Free Block的空間
  - Index Block大小設計亦是難題
    - 太小，不夠存放一個file的所有Block之編號；太大，又形成浪費

解決Index Block不夠大的三個方法

- 【方法1】
  - 利用多個(≥ 1)Index Blocks儲存，且Index Block之間以Link方式串連。
  - 範例：

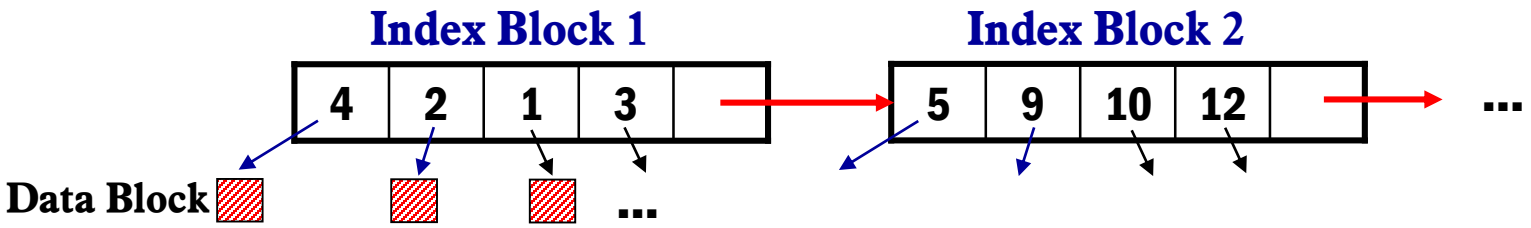

  - 適用於小檔案
  - Link斷裂，Data lost

【方法2】

- Multilevel Index (多層索引)
- 範例：2 level index

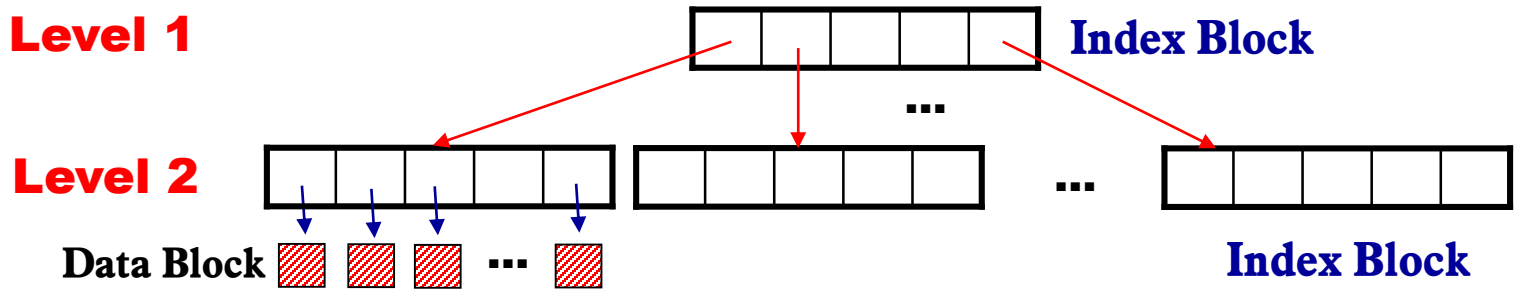

- 僅適用於大型檔案，小檔案不適合
  - ∵一旦系統的索引決定是2 level的，則不論檔案的大小，所使用的都是2 level的index!!當存到小檔案時，搞不好index的大小會大於檔案。

【方法3】

- 混合法，即 Unix 之 i-Node Structure。有15個項目 (Pointer)，可逐級累加使用。
  - 1~12號指標：儲存Data Block # (檔案的Block需求≤12個時適用)
  - 13號指標：指向Single-level Index
  - 14號指標：指向Two-level Index
  - 15號指標：指向Three-level Index
- 範例：

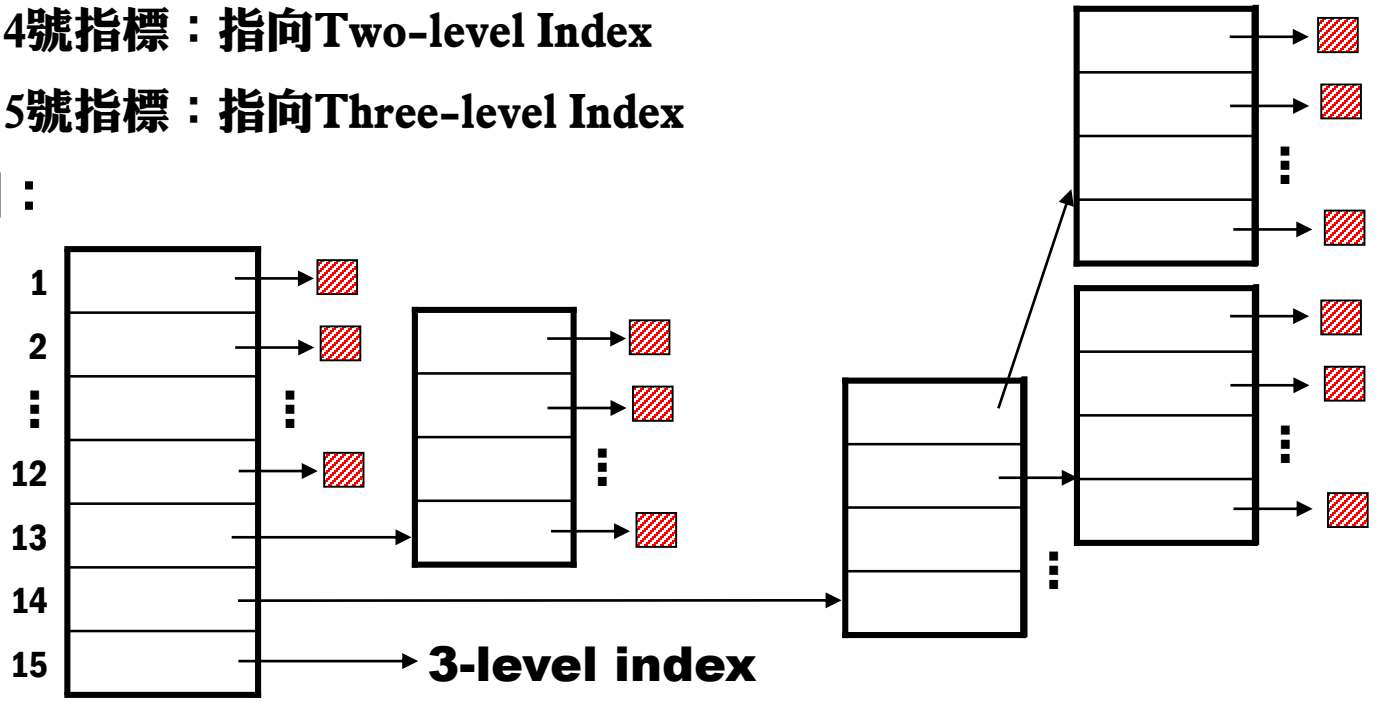

■磁碟陣列（RAID）

- Why RAID?
  - 電腦系統運作中，就以Disk效率最差 (∵機械式運作)
  - 安全性、可靠性議題日益重要
- RAID是由多顆磁碟機組成一個陣列(邏輯磁碟; Logical Disk)，將資料以切割(striping)的方式，同時對不同的磁碟做讀寫的動作。
  - 1個Byte的資料原本存放於1個磁碟上。若切割成8個bit分散存放於8個Disk上，且一次存取1個Byte資料，則可獲得8倍的傳輸速率。
  - 採“平行I/O”以提升效率。
  - 安全性、可靠性提升
  - 由OS進行資料的Striping與分散存取，故User僅看到一個大且速度快的邏輯磁碟空間(Logical Disk/Logical Device)。

- 依所使用的技術不同，定義出多種具有不同方式與效能的RAID 代號，簡稱RAID Level。
  - RAID 0, RAID 1, RAID 0+1, RAID 1+0, RAID 2, RAID 3, RAID 4, RAID 5, RAID 6, ...
  - Level高低不代表系統效能或可靠度的高低，端視管理員的需求。

RAID 0：

- 又稱Striping RAID
- 最少需要2顆磁碟
- 將資料切割存放到多部硬碟中，且不會重複存放。
- 以效能導向為主，可平行讀寫，適用於具有高效能需求的系統。
  - 理論上，硬碟越多效能就等於[單一硬碟效能]×[硬碟數]。事實上，受限於匯流排I/O瓶頸及其它硬體因素，RAID 效能會隨之遞減。
  - 所以，兩個硬碟的RAID 0最能感受到效能的提升。
- 缺點是完全沒有容錯能力，只要有一個磁碟故障，就會導致所有資料損毀，無法挽回。

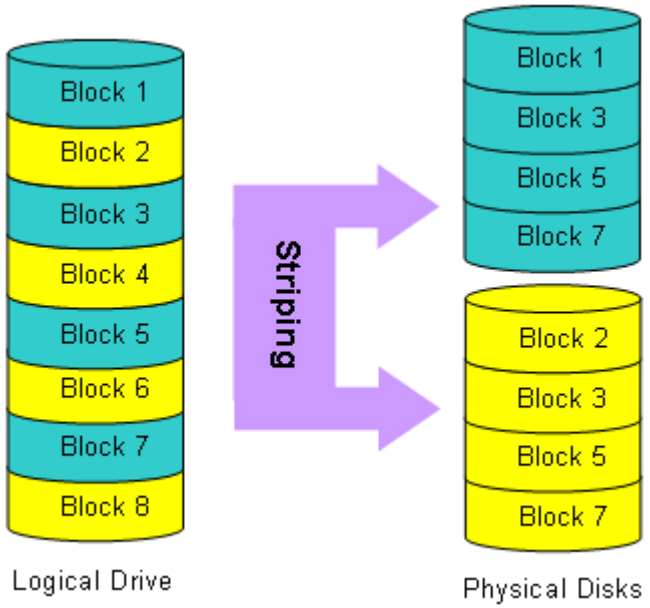

RAID 1：

- 又稱Mirror RAID
- 最少需要2個硬碟
- 有資料寫入時，直接同時寫入兩個硬碟，故其內部資料是完全一樣的。
- 其中一個硬碟可做為備份。當有一個硬碟故障時，另一個硬碟可讓系統正常運作，故可靠性高。
- Read效能佳，但Write效能差。
- 優點：系統可靠度很高，實作容易。
- 缺點：效率最差，且成本高。

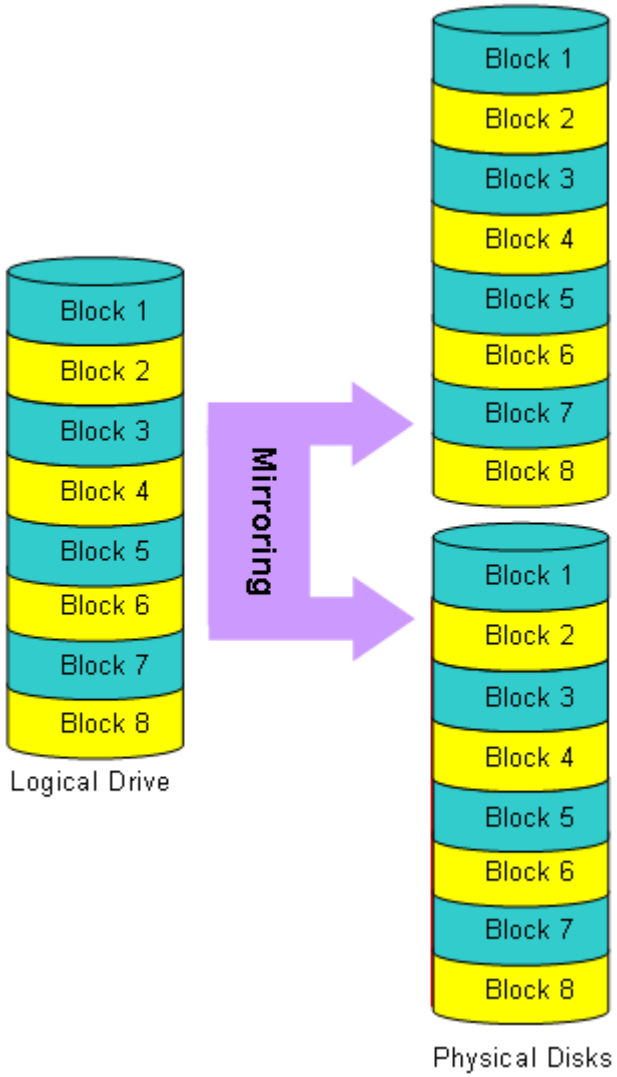

RAID 0+1 (RAID 01)： Striping + Mirror

- 結合了RAID 0與RAID 1兩種模式。在這樣的架構下，至少要4顆磁碟，且硬碟總數需為偶數。
- 由2個硬碟先進行RAID 0的Striping，再由RAID 1的Mirror做複製。
- 優點：Speed與安全性兼顧。
- 缺點：一次最少要用上4顆硬碟，而且也要浪費一半的總容量，成本很高。

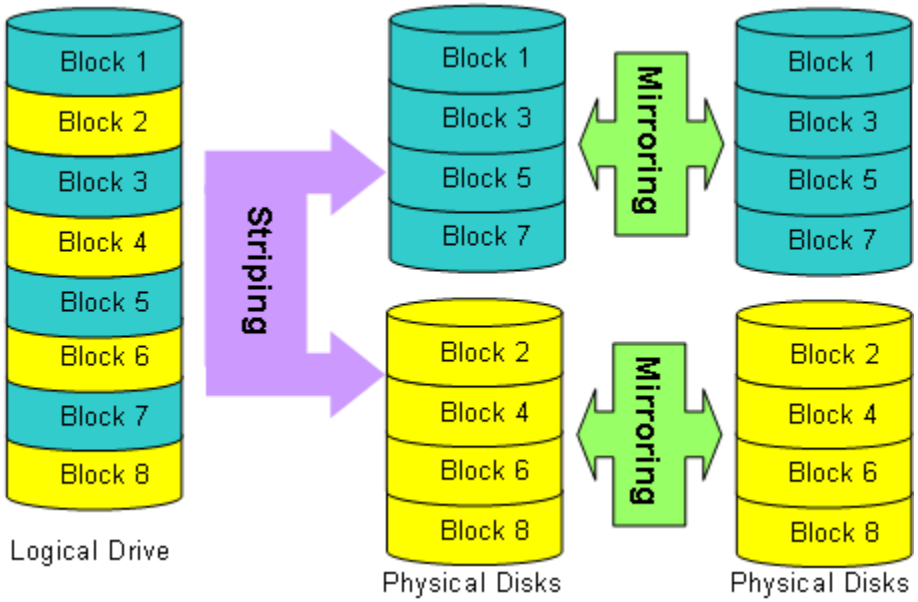

RAID 1+0 (RAID 10)：Mirror + Striping

- 結合了RAID 0與RAID 1兩種模式。在這樣的架構下，至少要4顆以上的磁碟，且硬碟總數需為偶數。
- 由2個硬碟先進行RAID 1的Mirror，再由RAID 0的Striping做複製。
- 可靠性較RAID 01高，但Speed較差。

RAID 2

- 為RAID 0的改良版，以漢明碼（Hamming Code）的方式進行資料編碼。
- 不同的位元儲存在不同的硬碟中。例如：4個Bits的資料需要7部硬碟來儲存，4部存資料，3部存Hamming Code。
- 因為加入了錯誤修正碼（ECC，Error Correction Code），具錯誤檢查與更正能力。所以當一部硬碟壞掉時，可由其它硬碟的內容來更正。

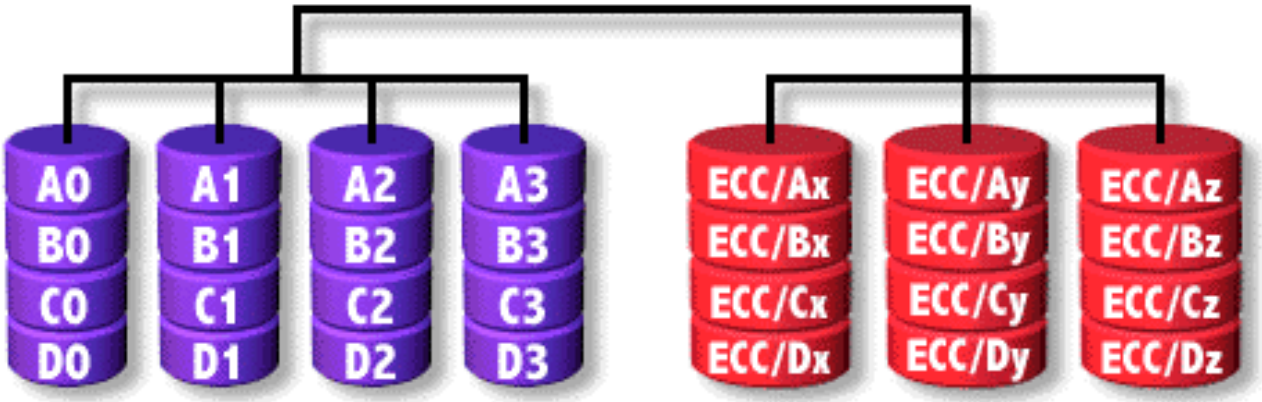

RAID 3：Parallel with Parity (平行同位元檢查)

- 資料切割以bit為單位
- 以同位元檢查為容錯機制
- 所有的同位元資料皆存放於同一個硬碟(Parity Disk)上
- 允許同時間有一個disk損壞，且仍可回復
- 問題：
  - Parity Disk會成為效能上的瓶頸 (RAID 4亦有此問題)。

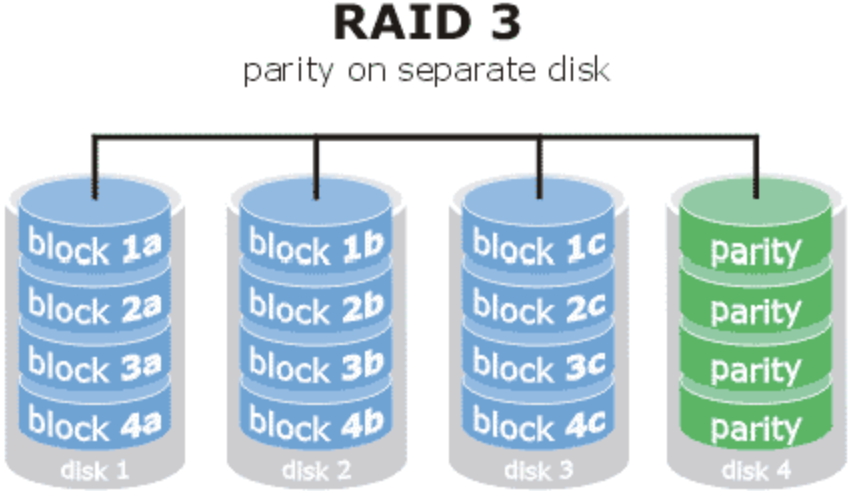

RAID 4：Parallel with Parity (平行同位元檢查)

- 跟RAID 3 相似，不同之處為資料切割是以Block 為單位。
- 效率較RAID 3佳。

RAID 5：

- 與RAID 4相似，資料切割是以Block為單位，但是RAID 5把同位元分散儲存於陣列中的每顆磁碟內。

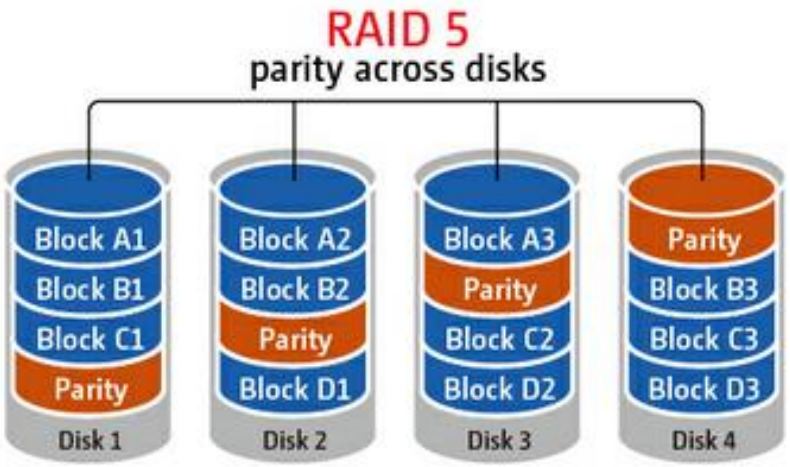

RAID 6：

- RAID 6 儲存2 份同位元資料(Double Parity)，讓系統即使損壞兩顆硬碟仍能進行資料回復。
- RAID 6的Write效能較RAID 5差，是因為資料寫入時的同位元校正機制必須執行兩次，即：計算同位元值和驗證資料正確性所花費的時間較多。
- 資料重建時，回復的時間也較RAID 5要多一倍。

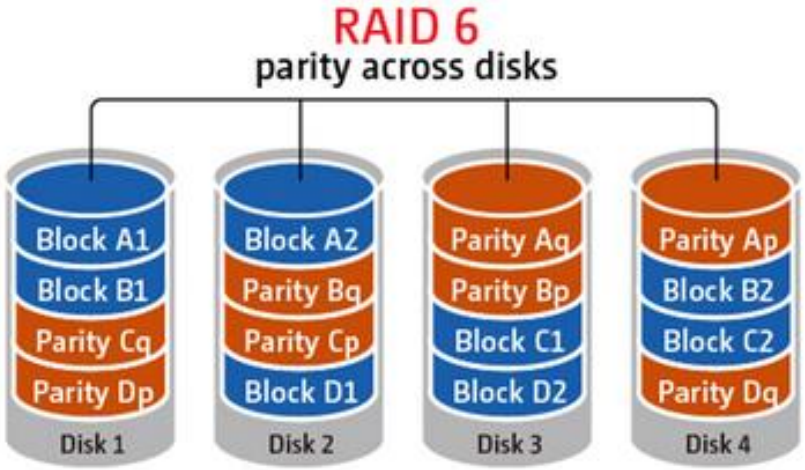

■固態硬碟（SSD）

- Solid State Disk
  - 相較於傳統旋轉式H.D.，為較進代的儲存裝置。
  - 採用SATA 3.0傳輸規格。

與傳統硬碟的比較：

	固態硬碟	傳統硬碟	
優點	電子式資料讀寫 ⇒抗震性佳 ⇒適用於行動裝置	機械式資料讀寫 ⇒抗震性差 ⇒適用於桌機或NB	缺點
	散熱需求低	散熱需求高	
	Random Access ⇒Speed快	Header移動 ⇒Speed慢	
缺點	成本高	成本低	優點
	容量小	容量大	
	顆粒有毀損，資料無法救回	磁面有毀損，資料有機會救回	

補 充

■錯誤碼的偵測與更正

- Parity Check (同位元檢查) -具偵測錯誤能力
- Hamming Code (漢明碼) -具偵測錯誤與更正錯誤能力

Parity Check (同位元檢查)

- 可分為：
  - 偶同位 (Even Parity)：訊息加上Parity Check Bit所形成的傳輸碼中，位元值為 “1” 之個數必須是偶數，才算正確。
  - 奇同位 (Odd Parity)：訊息加上Parity Check Bit所形成的傳輸碼中，位元值為 “1” 之個數必須是奇數，才算正確。
- 例：
  - 求下列傳送訊息所需補上的Parity check bit之值(採Even Parity)：
    - 訊息：1101000 ⇨ Parity Check Bit = 1
    - 訊息：0110011 ⇨ Parity Check Bit = 0
  - 下列何者傳輸碼不符合Odd Parity?
    - 1111111 (✓)
    - 1011100 (×)
    - 10000100 (×)

- **特點：**
  - Simple, Easy Implementation。
  - 用於ASCII，RAM資料傳輸檢視，RAID (磁碟冗餘陣列：RAID-3, RAID-4, RAID-5)等。
  - 若有偶數個bits同時出錯，則收方無法偵測出Error，會誤判傳輸資料為正確。
  - 不具更正錯誤能力。

Hamming Code (漢明碼)

- 傳輸碼 = 傳送訊息 + Hamming Code Bits (H.C. Bit)
  - 規定：H.C.Bit一定要出現在2的冪次方位置 ($2^0, 2^1, 2^2, 2^3, \ldots$)
  - 例：訊息為 1001001001，則傳輸碼：

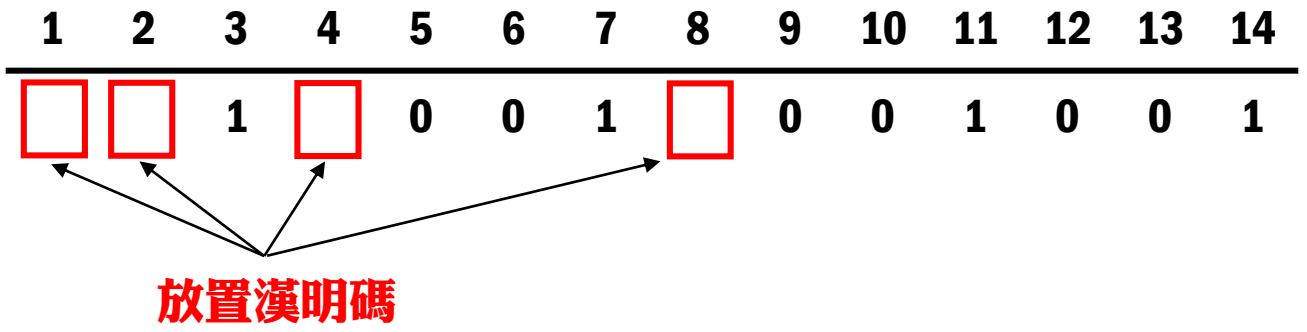

- H.C.Bit數目：
  - 公式：$2^k \geq n + k + 1$ (n: 訊息長度；k: H.C.Bit數，取最小的k)
    - 例：$n = 10 \Rightarrow 2^k \geq 10 + k + 1$，則最小的$k = 4$。

如何決定H.C.Bit的值？

- 作法：

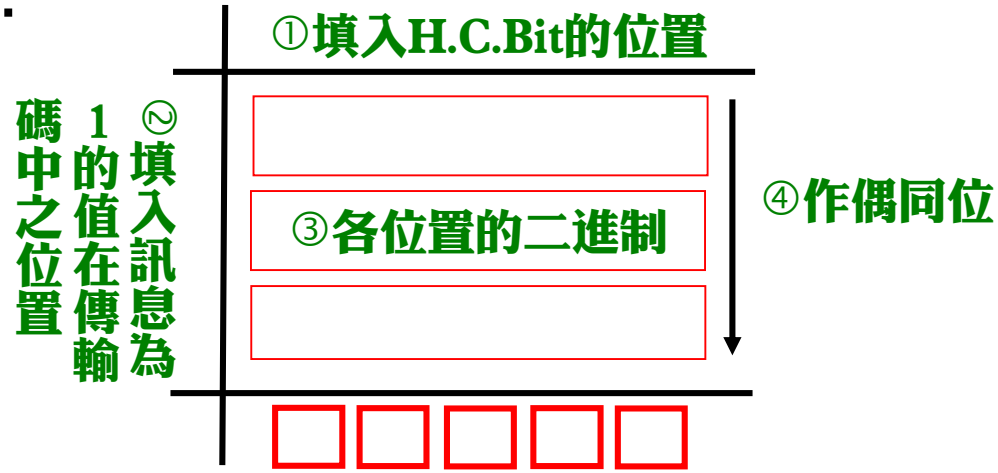

- 例：訊息為 1001001001，

  則傳輸碼為：

1 0 1 0 0 0 1 0 0 0 1 0 0 1

	8	4	2	1
3	0	0	1	1
7	0	1	1	1
11	1	0	1	1
14	1	1	1	0
	0	0	0	1

作偶同位

- 收方收到傳輸碼，如何判定有無錯誤？若錯誤，是哪個Bit有錯？
  - 作法：

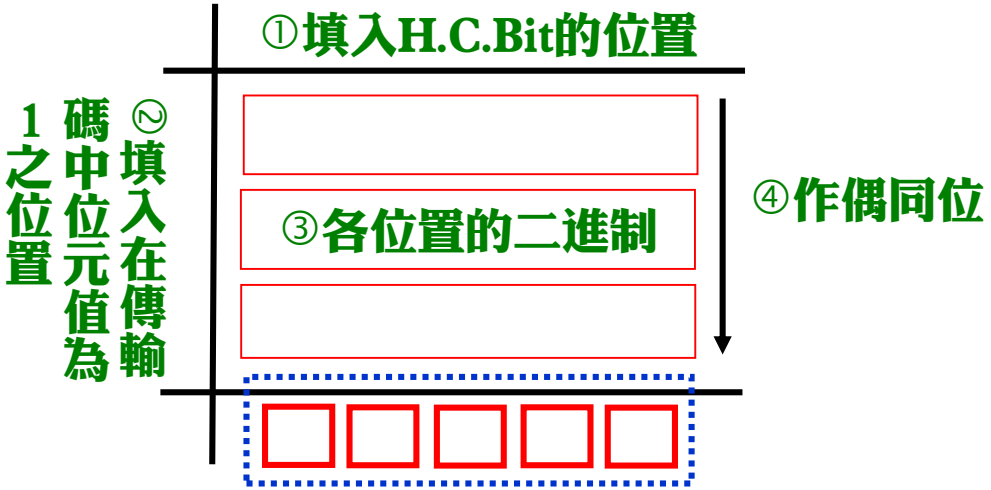

- 例：收方收到 1 0 1 0 0 0 1 0 1 0 1 0 0 1之H.C.Bit傳輸碼，請問有無error? 若有，請問錯第幾個?

	8	4	2	1
1	0	0	0	1
3	0	0	1	1
7	0	1	1	1
9	1	0	0	1
11	1	0	1	1
14	1	1	1	0
	1	0	0	1

作偶同位

轉成10進位

9，非零。∴傳輸碼有錯!!
錯誤位置為第9個位元。

- 正確的H.C.Bit傳輸碼應為：1 0 1 0 0 0 1 0 0 0 1 0 0 1
- 正確的傳送訊息為：1 0 0 1 0 0 1 0 0 1 (把H.C.Bit拿掉)